

LLM委员会考试系统

基于多Agent的自动考试

评估Agent最终裁定

Evaluation ID: d7dd6f33-d6ec-47c0-b0cf-3223ca9151e4

4.7/10

考官问题平均分

主席
评估

理解核心概念但缺乏严谨性与系统应用能力（表面理解层次）

综合两项深度测试的表现，该学生对大数乘法的基础算法（如知晓 $n+m$ 长度足够并可用实例验证），但处于'知其所以然'的认知层次。在Q1中，学生能通过 99×99 等感性验证，却未能构建基于不等式 $(10^n - 1)(10^m - 1) < 10^{n+m}$ 的严格数学证明，显露出数学严谨性的缺失；在Q2中，面对需求扩展，学生混淆了单字符串符号解析与双操作数乘法逻辑（如将'两个负数得正'作为字符串处理逻辑），表明其缺乏'预计算-后处理'的模块化设计思维。整体而言，学生能复现基础框架，但在边界分析、形式化证明及需求扩展时的系统架构存在明显短板，尚未达到灵活应用与深度理解的水平。

识别出的知识漏洞:

数学严谨性证明与边界分析能力（缺乏基于对数不等式的严格证明能力）

字符串预处理的系统化设计（未能建立符号解析、异常检测与模块化的架构思维）

边界条件与极端案例的完备性分析（Q1中未考虑前导零等边界组合场景分析混乱）

算法扩展时的状态管理（缺乏对符号位异或运算、补码概念或溢出条件的系统运用）

学习建议:

各维度详细评分（三阶段委员会流程）

每个问题经过多教师独立评分 → 同行评议校准 → 主席综合裁定

在你的代码中，result数组的长度被初始化为
1 $n+m$ 。请解释为什么这个长度足够容纳任意两个长度为 n 和 m 的正整数相乘的结果... 5.5 C (及格)

置信度: 中 教师数: 4 一致性: 中

1 教师委员会独立评分

kimi-k2.5

6.5/10

kimi-k2-0905-preview

4.0/10

kimi-k2-turbo-preview

5.5/10

kimi-k2-thinking

5.5/10

最严格: kimi-k2-0905-preview | 最宽松: kimi-k2.5

3 委员会主席详细评语

****最终得分**:** 5.5/10

****置信度**:** 中 (基于评分一致性)

****评定等级**:** C(5-5.9)

****委员会主席评语**:**

- ****综合评价**:** 该答案展现了学生对"两个 n 位和 m 位数相乘结果位数不超过 $n+m$ "这一核心结论的正确直觉，能够通过具体实例 (99×99) 进行直观验证，并尝试运用10的幂次进行数量级分析。然而，答案在数学严谨性、边界完整性及学术表达方面存在明显缺陷，处于"理解概念但无法严谨论证"的层次。

- ****主要优点**:** 抓住了位数上限的关键规律；能正确使用最大 n 位数 ($10^n - 1$) 进行估算；举例验证具有代表性；对数组长度需求有基本正确的工程直觉。

- ****关键不足**:** 1) 数学推导极不严谨，混淆了"数量级近似"与"严格不等式"，未证明 $(10^n - 1)(10^m - 1) < 10^{n+m}$ 从而确保位数 $\leq n+m$ ；2) ****完全缺失边界情况分析****，未讨论最小乘积 10^{n+m-2} (对应 $n+m-1$ 位) 与最大乘积的位数差

异，也未解释为何 $n+m-1$ 长度不够（如 $10 \times 10 = 100$ 的反例）；3）表达高度口语化（“呃”、“应该是因为”、“大概是”），缺乏学术写作的精确性。

- ****得分依据****：综合四位教师的独立评判（方差2.5，中分歧），委员会认为教师A（6.5）过于乐观，忽视了边界分析的硬性要求；教师B（4.0）过于严苛，忽略了学生对核心概念的正确把握。最终采纳教师C与D的5.5分作为平衡：既认可学生“方向正确但论证瑕疵”的实际情况，又强调在算法分析中****严格边界证明****的必要性——仅凭直觉“大概”不够，必须证明最坏情况（全9相乘）和最好情况（ $10 \dots 0$ 相乘）均能被 $n+m$ 长度容纳。

****学习建议****：

- **补足数学证明训练****：练习使用严格不等式证明位数上界，明确写出 $(10^n - 1)(10^m - 1) = 10^{n+m} - 10^n - 10^m + 1 < 10^{n+m}$ ，并理解 10^{n+m} 是 $n+m+1$ 位数而乘积严格小于它。
- **建立边界分析习惯****：在分析算法空间/时间复杂度时，必须同时考虑****上界（最坏情况）****和****下界（最好情况）****，明确说明为何 $n+m-1$ 长度不足（举例： $100 \times 100 = 10000$ ， $2+2=4$ 位，但 $n+m-1=3$ 不够）。
- **学术表达规范化****：删除“呃”、“大概”等口语填充词，使用“设...则...”、“由此可得”等逻辑连接词，数学符号（如 $\times$ 、 $\leq$ 、 $\in$ ）需规范书写，形成“定义→推导→结论”的闭环论述结构。

学生回答预览

呃，长度设为 $n+m$应该是因为.....两个数相乘，位数加起来就是最多可能的长度吧？比如说.....99乘99是9801，两位数乘两位数，结果最多四位， $2+2=4$ 。对，应该就是这样，所以 $n+m$ 够用了。具体数学推导.....就是最大的 n 位数是 $10^n - 1$ ，乘 $10^m - 1$ ，大概是 10^{n+m} ，所以是 $n+m$ 位？

假设现在要求你的代码能够处理带符号的整数（即
2 输入字符串可能以'-'开头表示负数，也可能没有符**3.8**
号表示正数），请描述你需要对...

D
(不
及
格)

置信度: 中 教师数: 4 一致性: 高

评分分布

优秀 (9-10)

0

良好 (7-8)	0
中等 (5-6)	1
待改进 (<5)	1

评估流程说明

1

多教师
独立评分

2

同行评议
交叉校准

3

主席综合
最终裁定

开始新的评估